


vllm支持的量化方式(只量化权重):

GPTQ, AWQ, Bitsandbytes, GGUF, online quantization, LLM Compressor(vllm提供的量化工具, 支持 w4/6a16和w8a8(int8,fp8)), NVFP4 (w4a4)、MXFP4/8、FP8 KV Cache等等。

vllm中的激活值量化方式 (一般推理时动态量化) :

dynamic_per_token, dynamic_per_group等等

vllm支持的量化后端 (量化后的模型怎么算) :



vllm量化推理过程:

先根据量化后的权重格式, 每层的输入 (激活值) 描述, 硬件能力以及可用的kernel决定是否需要对激活值量化, 计算语义是什么 (w8a16还是w8a8), 选择哪个后端, 整体forward流程: Quantization Format(规定: W 是什么格式、A 是什么格式、dynamic / static、token / tensor / group、group_size、scale 类型) / Scheme -> vLLM Quantization Method (解析 checkpoint、识别量化 scheme、为每层建立量化执行逻辑) -> Kernel Backend -> Hardware(决定: 哪些 kernel 可以使用, 是否拥有原生 FP4/FP8 Tensor Core)。

结论: 量化后的权重是否包含对应量化语义 (w4a16, w4a4) + 硬件支持决定了最后量化推理的过程。